

Contents

1. Cargar librerías	1
2. Definir archivos y etiquetas	3
3. Leer y CONVERTIR las secuencias	3
3.1 Cálculo y graficación de las longitudes	3
4. Cálculo de k-mers	4
5. Generar la matriz de distancia y el cluster	4
6. Graficar	4
7. Interpretación	5
Video de Youtube	5
Referencias	5

-
- **Nombre:** Diego Hernández Rangel
 - **Matrícula:** A01710524
 - **Campus:** Tecnológico de Monterrey, Querétaro
 - **Materia:** Análisis de biología computacional (Gpo 201)
 - **Profesor:** Gerardo Javier Alanis Funes
-

1. Cargar librerías

Se cargan las herramientas necesarias para el análisis bioinformático: Biostrings para manipular secuencias de ADN, kmer para el análisis de frecuencias de nucleótidos y ape para la generación de estructuras filogenéticas.

```
library(Biostrings)
```

```
## Loading required package: BiocGenerics
## Loading required package: generics
##
## Attaching package: 'generics'
## The following objects are masked from 'package:base':
##
```

```

##      as.difftime, as.factor, as.ordered, intersect, is.element, setdiff,
##      setequal, union

##
## Attaching package: 'BiocGenerics'

## The following objects are masked from 'package:stats':
##
##      IQR, mad, sd, var, xtabs

## The following objects are masked from 'package:base':
##
##      anyDuplicated, aperm, append, as.data.frame, basename, cbind,
##      colnames, dirname, do.call, duplicated, eval, evalq, Filter, Find,
##      get, grep, grepl, is.unsorted, lapply, Map, mapply, match, mget,
##      order, paste, pmax, pmax.int, pmin, pmin.int, Position, rank,
##      rbind, Reduce, rownames, sapply, saveRDS, table, tapply, unique,
##      unsplit, which.max, which.min

## Loading required package: S4Vectors

## Loading required package: stats4

##
## Attaching package: 'S4Vectors'

## The following object is masked from 'package:utils':
##
##      findMatches

## The following objects are masked from 'package:base':
##
##      expand.grid, I, unname

## Loading required package: IRanges

## Loading required package: XVector

## Loading required package: Seqinfo

##
## Attaching package: 'Biostrings'

## The following object is masked from 'package:base':
##
##      strsplit
library(ape)

##
## Attaching package: 'ape'

## The following object is masked from 'package:Biostrings':
##
##      complement
library(kmer)

```

2. Definir archivos y etiquetas

Se especifican las rutas de los archivos .fasta que contienen los genomas de las variantes de SARS-CoV-2 y se crea un vector con los nombres de los países correspondientes para etiquetar el gráfico final

```
files <- c(
  "data/PZ357334.1.fasta",
  "data/NC_045512.2.fasta",
  "data/PZ055857.1.fasta",
  "data/PV125869.1.fasta",
  "data/PZ253834.1.fasta",
  "data/PX471304.1.fasta",
  "data/PX404732.1.fasta",
  "data/LC929404.1.fasta",
  "data/PV910446.1.fasta",
  "data/PZ011000.1.fasta"
)

países <- c("USA", "China", "India", "Francia", "Alemania",
            "Brasil", "Corea", "Japon", "Italia", "UK")
```

3. Leer y CONVERTIR las secuencias

Se importan los datos genéticos. Para que la función de conteo funcione correctamente, las secuencias se convierten de formato DNASTringSet a caracteres simples y luego se dividen en letras individuales, asignando los nombres de los países a cada secuencia.

```
dna_sequences <- readDNASTringSet(files)


sequences_list <- as.character(dna_sequences)
sequences_list <- strsplit(sequences_list, "")
names(sequences_list) <- países
```

3.1 Cálculo y graficación de las longitudes

En esta sección se mide el tamaño total de cada genoma para verificar si existen variaciones significativas en la cantidad de material genético entre las variantes. Primero, se calcula el número exacto de bases nitrogenadas (longitud) de cada secuencia de ADN. Después, se genera una gráfica de barras comparativa.

```
sequence_lengths <- width(dna_sequences)
names(sequence_lengths) <- países
barplot(sequence_lengths,
  main = "Comparativa del Tamaño Genómico de Variantes SARS-CoV-2",
  xlab = "País / Variante",
  ylab = "Número de Bases (pb)",
  col = "skyblue",
  las = 2,
  ylim = c(29000, 30000),
  xpd = FALSE)
```

Comparativa del Tamaño Genómico de Variantes SARS-CoV-2



4. Cálculo de k-mers

Se calculan los tetranucleótidos ($k = 4$), que consiste en contar la frecuencia de todas las combinaciones posibles de 4 letras (A, C, G, T) en cada genoma para obtener una “huella digital” genética.

```
counts <- kcount(sequences_list, k = 4)
```

5. Generar la matriz de distancia y el cluster

Se calcula una matriz de distancia basada en las diferencias de las frecuencias de k-mers. Posteriormente, se aplica un agrupamiento jerárquico (hclust) con el método “complete” para organizar a los países según su similitud genética.

```
dist_matrix <- dist(counts)
hc <- hclust(dist_matrix, method = "complete")
```


6. Graficar

Se genera el dendrograma (árbol). Se eliminan las etiquetas por defecto del eje X para añadir manualmente el título “País” y la descripción del método (k-mers) en los márgenes inferiores utilizando la función mtext.

```
plot(as.dendrogram(hc),
     main = "Árbol Filogenético Variantes de SARS-CoV-2 a nivel mundial",
     ylab = "Distancia Genética",
     xlab = "",
     sub = "")
```

```
mtext("País", side = 1, line = 3, font = 1)
mtext("Basado en frecuencias de tetranucleótidos (k-mers)", side = 1, line = 4, cex = 0.8)
```

Árbol Filogenético Variantes de SARS-CoV-2 a nivel mundial



7. Interpretación

Aunque el SARS-CoV-2 muta constantemente, el “tamaño” total de su manual de instrucciones (genoma) casi no cambia. Todas las variantes analizadas miden alrededor de 29,900 letras de ADN. Esto nos dice que el virus es muy eficiente: cambia letras específicas para adaptarse, pero no suele perder ni ganar grandes fragmentos de información genética.

El árbol filogenético de image_5d1d52.png agrupa a los países según la similitud de las “huellas” genéticas de sus variantes de SARS-CoV-2; por ejemplo, la cercanía entre USA y Alemania o Corea y Japón sugiere que sus virus comparten mutaciones muy parecidas o rutas de contagio directas. En contraste, Francia se separa del grupo principal, lo que indica una mayor divergencia en su composición de nucleótidos. Este análisis confirma que, aunque el virus mantiene una estructura básica estable, evoluciona de forma distinta en cada región para adaptarse, tal como explican las investigaciones sobre su origen y propagación.

Video de Youtube

<https://www.youtube.com/watch?v=5toPDbsSHPo>

Referencias

[0] Zhou, P., Yang, X. L., Wang, X. G., Hu, B., Zhang, L., Zhang, W., Si, H. R., Zhu, Y., Li, B., Huang, C. L., Chen, H. D., Chen, J., Luo, Y., Guo, H., Jiang, R. D., Liu, M. Q., Chen, Y., Shen, X. R., Wang, X.,

Zheng, X. S., ... Shi, Z. L. (2020). A pneumonia outbreak associated with a new coronavirus of probable bat origin. *Nature*, 579(7798), 270–273. <https://doi.org/10.1038/s41586-020-2012-7>

[1] Lam, T. T., Jia, N., Zhang, Y. W., Shum, M. H., Jiang, J. F., Zhu, H. C., Tong, Y. G., Shi, Y. X., Ni, X. B., Liao, Y. S., Li, W. J., Jiang, B. G., Wei, W., Yuan, T. T., Zheng, K., Cui, X. M., Li, J., Pei, G. Q., Qiang, X., Cheung, W. Y., ... Cao, W. C. (2020). Identifying SARS-CoV-2-related coronaviruses in Malayan pangolins. *Nature*, 583(7815), 282–285. <https://doi.org/10.1038/s41586-020-2169-0>

[2] Organización Mundial de la Salud. (s.f.). WHO Coronavirus (COVID-19) dashboard. Recuperado el 2 de mayo de 2026, de <https://data.who.int/dashboards/covid19/cases?n=c>

[3] National Center for Biotechnology Information. (s.f.). PubMed. National Library of Medicine. <https://www.ncbi.nlm.nih.gov/>